

# Detecção e Reconhecimento de Sinais de Trânsito Brasileiros utilizando algoritmos AdaBoost e SIFT

Rafael Francisco Ferreira

Ciência da Computação  
Universidade Estadual do Paraná

# Índice

1. Introdução.
2. Referencial Teórico.
3. Metodologia.
4. Experimentos e Resultados.
5. Conclusão.

## Contexto

- 1,25 milhões morrem em acidentes de trânsito a cada ano;
- Causa principal de morte entre os jovens com idade entre 15 e 29 anos;
- 90% das mortes nas vias públicas ocorrem em países de baixa e média renda;
- Dados: OMS.

# Objetivo


- Detecção e reconhecimento automáticos;
- Utilização de meios visuais (Visão Computacional);
- Utilização dos algoritmos AdaBoost e SIFT;
- Menor tempo de processamento em relação aos resultado da proposta de Silva et al. em *“Uma Metodologia para Detectar e Reconhecer Placas de Sinalização de Trânsito”*.

# Haar-like


- Detector de Viola e Jones;
- Características retangulares;
- Diferenças de somas de pixels específicos;
- Comparação com limiar;
- Cascata de classificadores;
- Janela deslizando sobre a imagem.

# Haar-like


Características de Borda:



Características de Linha:



Características Pontuais:



Características Haar-like.

$$C = \sum \text{região escura} - \sum \text{região clara}$$

# AdaBoost

- Adaptive Boosting;
- Aprimora o desempenho de um algoritmo de aprendizado;
- Transforma classificadores “fracos” em “fortes”;
- Combina classificadores gerados pelo algoritmo base;
- Ajuste de acordo com os erros cometidos pelo classificador anterior;
- Gera um classificador melhor e mais eficiente.

O diagrama ilustra o processo de construção de um modelo de ensemble iterativo:

- Conjunto inicial de treinamento**: Representado por  $S$ .
- Normalização inicial**: Representado por  $D_0$ .
- Distribuição de probabilidade atribuída aos exemplos de treinamento na iteração  $T$** : Representado por  $D_1, D_2, D_3, D_4, \dots, D_T$ .
- Classificador gerado**: Representado por  $h_1, h_2, h_3, \dots, h_T$ .
- Hipótese**: Representado por  $H(x)$ .

As setas indicam o fluxo de dados:  $S \rightarrow D_0 \rightarrow D_1$ . Para cada iteração  $T$ , a distribuição  $D_T$  é usada para gerar o classificador  $h_T$ . Os classificadores  $h_1, h_2, h_3, \dots, h_T$  são combinados para formar a hipótese final  $H(x)$ . A importância  $\gamma_1$  é associada a cada exemplo.

## Esquema de funcionamento do algoritmo AdaBoost.



# SIFT

- Scale Invariant Feature Transform;
- Conjunto denso de vetores descritores;
- Invariantes a translação, rotação e escala;
- Processo de filtragem em estágios;

# SIFT

- Identifica posições chave no espaço-escala;
- Busca por posições de máximo ou mínimo de uma função de diferença de Gaussianas;
- Aproximação do Laplaciano da Gaussiana;

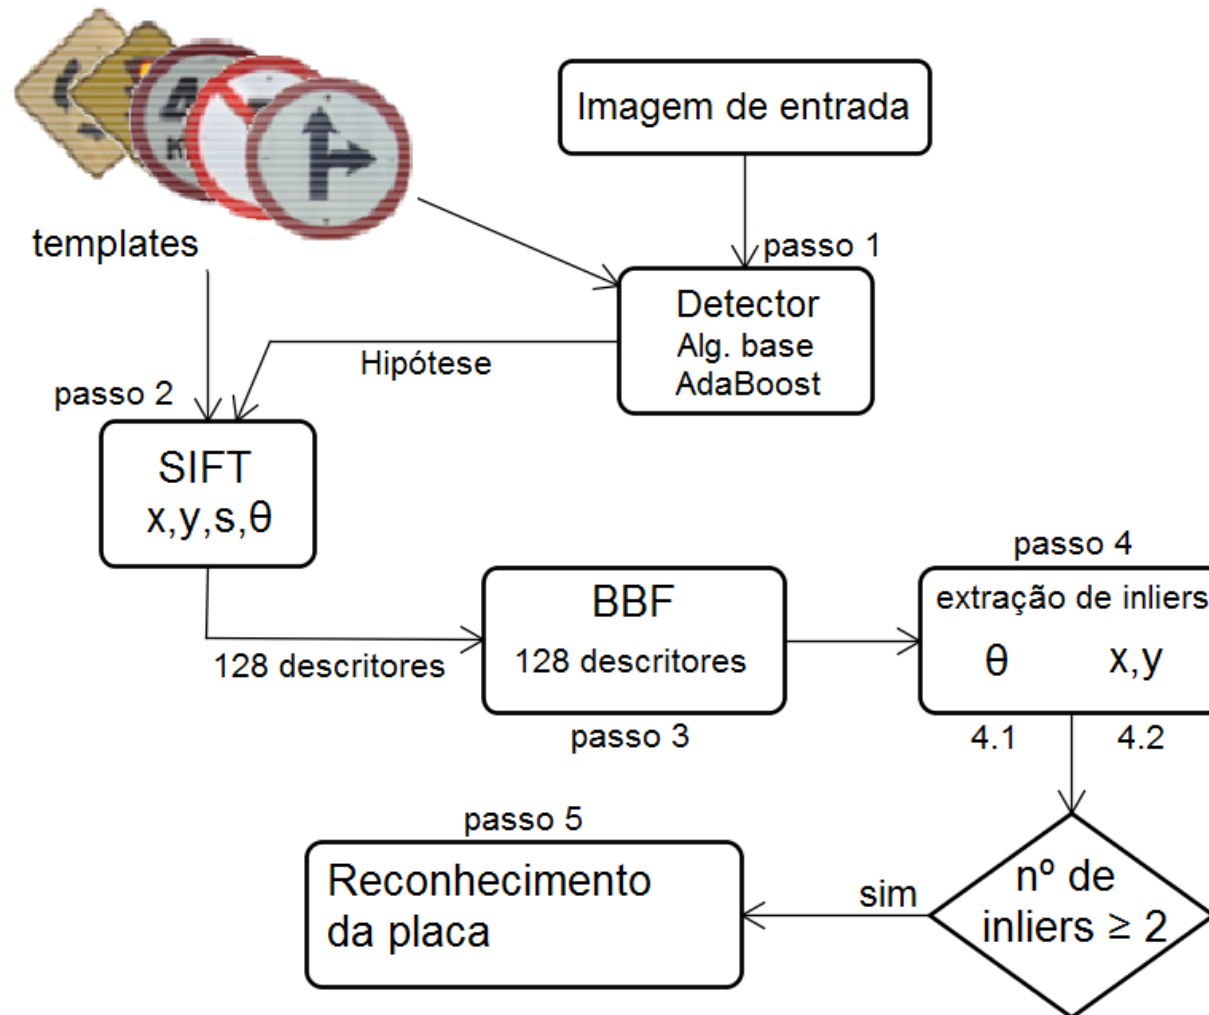
# SIFT

- Cada ponto gera um vetor de descritores;
- Descrição em relação aos eixos de coordenadas espaço-escala;
- Coordenadas espaciais;
- Coordenadas no eixo das escalas;
- Vizinhança.

# BBF

- Best Bin First;
- Algoritmo heurístico;
- Busca binária balanceada;
- Busca vizinhos mais próximos.

# Metodologia



Metodologia proposta.

# Experimento I

- 1.958 imagens;
- Filme com 90 minutos de duração;
- Taxa de captura de 29 quadros por segundo;
- Múltiplos de oito (0, 8, 16, ..., 1.957);

# Experimento I

- 5.300 imagens positivas;
- 11.200 imagens negativas;
- Trajeto de aproximadamente 4.000 metros;
- Câmera: JVC Full HD GZ-EX210BUB;
- Velocidade média de 30 km/h;


# Experimento I

	Positivas	Negativas	Estágios	Tamanho
Circular	2.892	6.000	25	24 x 24
Alerta	608	1200	20	24 x 24
Pare	900	2.000	20	24 x 24
Preferência	950	2.000	20	24 x 24

Classes de placas utilizadas no treinamento.



# Experimento I



Exemplos de imagens positivas: a) originais;  
b) usadas no treinamento, apenas com informações básicas;  
c) usadas diretamente no treinamento.

# Experimento I




Exemplos de imagens negativas.

# Experimento I



Templates das placas de trânsito extraídos do vídeo.

# Resultados I



Exemplos de resultados do Experimento I.

## Experimento II

- 60 imagens;
- 2144 x 1424 pixels;
- Câmera: Nikon D300S;
- Veículo em movimento;
- Condições normais de tráfego;
- Comparação com solução similar proposta por Silva et al.

# Experimento II



Sinais de trânsito utilizados como template.



## Resultados II

- 73 placas de sinalização nas 60 imagens;
- Reconhecidas corretamente: 58 placas (79.45%);
- Erros de identificação: 2 placas (2.74%);
- Não reconhecidas: 13 placas (17.81%);
- Tempo médio de processamento: 7.4 segundos;
- Intel Core i3 M330 2.13 GHz (RAM de 4 Giga Bytes).

## Resultados II (Silva et al.)

- 73 placas de sinalização nas 60 imagens;
- Reconhecidas corretamente: 62 placas (84.93%);
- Erros de identificação: 0;
- Não reconhecidas: 11 placas (15.07%);
- Tempo médio de processamento: **90 segundos**;
- Intel Core i3 M330 2.13 GHz (RAM de 4 Giga Bytes).



## Resultados II

<i>Templates</i>	Metodologia proposta por Silva et al.			Metodologia proposta neste trabalho		
	Acertos	Erros	Não reconhecidas	Acertos	Erros	Não reconhecidas
1	4 (100%)	0 (0%)	0 (0%)	3 (75%)	0 (0%)	1 (25%)
2	3 (100%)	0 (0%)	0 (0%)	2 (67%)	0 (0%)	1 (33%)
3	14 (73,68%)	0 (0%)	5 (26,32%)	16 (84,21%)	0 (0%)	3 (15,79%)
4	0 (0%)	0 (0%)	1 (100%)	0 (0%)	0 (0%)	1 (100%)
5	4 (100%)	0 (0%)	0 (0%)	3 (75%)	1 (25%)	0 (0%)
6	5 (100%)	0 (0%)	0 (0%)	3 (60%)	1 (20%)	1 (20%)
7	7 (77,78%)	0 (0%)	2 (22,22%)	5 (55,56%)	0 (0%)	4 (44,44%)
8	8 (100%)	0 (0%)	0 (0%)	8 (100%)	0 (0%)	0 (0%)
9	4 (66,67%)	0 (0%)	2 (33,33%)	6 (100%)	0 (0%)	0 (0%)
10	1 (100%)	0 (0%)	0 (0%)	1 (100%)	0 (0%)	0 (0%)
11	2 (100%)	0 (0%)	0 (0%)	2 (100%)	0 (0%)	0 (0%)
12	6 (100%)	0 (0%)	0 (0%)	5 (83,33%)	0 (0%)	1 (16,67%)
13	1 (100%)	0 (0%)	0 (0%)	1 (100%)	0 (0%)	0 (0%)
14	3 (75%)	0 (0%)	1 (25%)	3 (100%)	0 (0%)	1 (25%)

Resultados no reconhecimento das placas.

# Conclusão

- Taxa de acertos razoável;
- Qualidade dos resultados mantida;
- Tempo de processamento relativamente baixo;
- Solução merece atenção;
- Melhorias no tempo de processamento e eficiência.

## Mais Informações

- P. Viola and M.J. Jones, “*Robust real-time object detection*”, Second International Workshop on Statistical and Computational Theories of Vision – Modeling, Learning, Computing and Sampling, July 13, 2001.
- Lowe, D. , “*Object Recognition from Local Scale-Invariant Features*”, International Conference on Computer Vision, Greece, 1999, pp. 1150-1157.
- F.A. Silva, A.O. Artero, M.S.V. Paiva e R.L. Barbosa, “*Uma Metodologia para Detectar e Reconhecer Placas de Sinalização de Trânsito*”, VIII Workshop de Visão Computacional (WVC 2012). Anais, Goiás: UFG, 2012.